PredictMain
PREDICTIVE MAINTENANCE

EDT

CORPUS DE CONOCIMIENTO

PredictMain

Mantenimiento predictivo mediante aprendizaje automático

Documento técnico y académico

Universidad	Universidad Tecnológica de Nezahualcóyotl
División	División de Tecnologías de la Información
Asignatura	Formulación de Proyectos de Tecnología
Grupo	G050-701M
Integrantes	Antonio Santos Lizandro · Fátima Guadalupe Baez García · Luis Antonio Bautista Patiño · Jessica Beatriz Cruz Jaime · María Isabel Mérida López
Versión	2.0 — Corpus verificado
Fecha	octubre de 2026
Dataset de referencia	AI4I 2020 Predictive Maintenance Dataset
Fuente de datos	UCI Machine Learning Repository

Declaración de autenticidad y alcance

Este documento contiene una síntesis técnica elaborada a partir de la documentación oficial del dataset AI4I 2020, la descarga del archivo oficial `ai4i2020.csv` y las investigaciones académicas citadas al final. Los resultados numéricos del dataset que aparecen en este corpus fueron comprobados directamente sobre el archivo oficial descargado desde UCI.

> **Aclaración fundamental:** AI4I 2020 es un dataset oficial y reproducible, pero sus observaciones son **sintéticas**. No son mediciones originales capturadas directamente de una planta industrial. El dataset fue diseñado para representar datos realistas de mantenimiento predictivo y está basado en el comportamiento de una máquina de fresado.

1. Descripción del corpus

Este corpus reúne y sintetiza conocimiento técnico y académico relacionado con el mantenimiento predictivo de maquinaria industrial mediante aprendizaje automático.

Su contenido integra investigaciones sobre:

- El dataset AI4I 2020.
- Clasificación de fallas de maquinaria.
- Comparación de modelos de aprendizaje automático.
- Aprendizaje profundo aplicado al mantenimiento predictivo.
- Desbalance de clases.
- Escasez de registros de falla.
- Selección de características.
- Ingeniería y extracción de características.
- Validación y evaluación de modelos.
- Predicción en tiempo real.
- Datos sintéticos frente a datos industriales reales.
- Internet of Things aplicado a maquinaria.
- Limitaciones y generalización de los modelos.

El corpus no es una lista de enlaces. Es una **base de conocimiento sintetizada**, donde cada investigación se relaciona con los conceptos, datos, algoritmos, resultados y decisiones relevantes para PredictMain.

---

2. Problema central del dominio

El mantenimiento reactivo interviene después de que la maquinaria presenta una falla. Este enfoque puede provocar:

- Paros no planificados.
- Pérdidas económicas.
- Interrupciones en la producción.
- Reparaciones urgentes.
- Sustitución prematura o tardía de componentes.
- Falta de información para priorizar las actividades de mantenimiento.

El mantenimiento predictivo busca utilizar mediciones de la maquinaria y registros históricos para identificar patrones asociados con el deterioro o la falla antes de que ocurra un evento crítico.

En un sistema de mantenimiento predictivo, el modelo recibe variables de operación y produce una estimación, por ejemplo:

Entrada	Proceso	Salida esperada
Temperatura, velocidad, torque y desgaste	Modelo de clasificación o detección	Riesgo de falla
Historial de fallas	Análisis de patrones	Tipos de comportamiento asociados a fallas
Variables de sensores	Ingeniería de características	Indicadores de condición
Datos históricos	Entrenamiento y validación	Modelo predictivo
Resultado del modelo	Interpretación de negocio	Recomendación de inspección o mantenimiento

La dificultad principal consiste en que los datos industriales no siempre son abundantes, equilibrados, completos o representativos de todos los escenarios posibles.

---

3. AI4I 2020 Predictive Maintenance Dataset

3.1 Identificación

Campo	Información
Nombre	AI4I 2020 Predictive Maintenance Dataset
Repositorio	UCI Machine Learning Repository
Año de donación	2020
Tipo	Dataset sintético de mantenimiento predictivo
Características	Multivariado y de series temporales
Tareas asociadas	Clasificación, regresión y descubrimiento causal
Registros	10,000
Variables documentadas	14 columnas en el archivo original
Valores faltantes	No contiene valores faltantes en la versión oficial
DOI	10.24432/C5HS5C
Licencia	Creative Commons Attribution 4.0 International
Fuente oficial	UCI Machine Learning Repository

3.2 Propósito del dataset

El dataset fue creado porque los datos reales de mantenimiento predictivo son difíciles de obtener y publicar. Su objetivo es representar, de forma sintética, datos de operación de una máquina industrial y diferentes modos de falla.

El dataset es apropiado para experimentar con:

- Clasificación binaria de falla y no falla.
- Clasificación de modos de falla.
- Comparación de algoritmos.
- Balanceo de clases.
- Selección de variables.
- Evaluación de métricas.
- Interpretabilidad de modelos.

No debe interpretarse como una representación completa de una planta industrial real. Su utilidad principal es experimental y educativa.

3.3 Variables del dataset

Variable	Tipo	Papel	Unidad o descripción
`UID`	Entera	Identificador	Identificador único del registro.
`Product ID`	Categórica	Identificador	Identificador del producto y número de serie.
`Type`	Categórica	Característica	Calidad del producto: L, M o H.
`Air temperature`	Continua	Característica	Temperatura del aire en Kelvin.
`Process temperature`	Continua	Característica	Temperatura del proceso en Kelvin.
`Rotational speed`	Entera	Característica	Velocidad de rotación en rpm.
`Torque`	Continua	Característica	Torque en Nm.
`Tool wear`	Entera	Característica	Desgaste de la herramienta en minutos.
`Machine failure`	Entera/binaria	Objetivo	Indica si ocurrió una falla de máquina.
`TWF`	Entera/binaria	Objetivo auxiliar	Tool Wear Failure.
`HDF`	Entera/binaria	Objetivo auxiliar	Heat Dissipation Failure.
`PWF`	Entera/binaria	Objetivo auxiliar	Power Failure.
`OSF`	Entera/binaria	Objetivo auxiliar	Overstrain Failure.
`RNF`	Entera/binaria	Objetivo auxiliar	Random Failure.

3.4 Tipos de producto

Tipo	Significado	Proporción aproximada
`L`	Variante de producto indicada por la documentación	6,000 registros observados; 60.00 %
`M`	Variante de producto indicada por la documentación	2,997 registros observados; 29.97 %
`H`	Variante de producto indicada por la documentación	1,003 registros observados; 10.03 %

La documentación de UCI describe una distribución conceptual de tipos L, M y H, pero la distribución comprobada en el archivo descargado no coincide exactamente con una proporción 50/30/20. Para PredictMain se conservará la distribución real observada en el archivo: L=6,000, M=2,997 y H=1,003. Esta diferencia queda registrada como una observación de calidad y trazabilidad, no se corrige artificialmente.

El tipo de producto influye en determinadas condiciones del proceso, como el desgaste acumulado de la herramienta y los límites asociados con la sobrecarga.

3.5 Generación de las variables

Variable	Comportamiento descrito
Temperatura del aire	Se genera mediante un proceso de caminata aleatoria y se normaliza alrededor de 300 K.
Temperatura del proceso	Se relaciona con la temperatura del aire y se mantiene aproximadamente 10 K por encima.
Velocidad de rotación	Se calcula a partir de una potencia de referencia y contiene ruido con distribución normal.
Torque	Se distribuye alrededor de 40 Nm, con una desviación aproximada de 10 Nm y sin valores negativos.
Desgaste de herramienta	Aumenta según el uso y recibe incrementos relacionados con el tipo de producto.

3.6 Modos de falla

3.6.1 Tool Wear Failure — TWF

La herramienta puede fallar cuando su desgaste alcanza un tiempo seleccionado aleatoriamente dentro del intervalo de aproximadamente 200 a 240 minutos.

Elemento	Descripción
Variable relacionada	`Tool wear`
Tipo de fenómeno	Desgaste acumulado
Posible señal	Aumento progresivo del tiempo de uso
Riesgo de modelado	Un modelo puede aprender el umbral sin comprender el contexto completo

3.6.2 Heat Dissipation Failure — HDF

La falla de disipación térmica puede ocurrir cuando la diferencia entre la temperatura del aire y la temperatura del proceso es menor que aproximadamente 8.6 K y la velocidad de rotación es inferior a aproximadamente 1380 rpm.

Elemento	Descripción
Variables relacionadas	Temperatura del aire, temperatura del proceso y rpm
Relación derivada	Diferencia entre temperaturas
Tipo de problema	Condición térmica y de velocidad
Implicación	Es importante analizar variables combinadas, no solo variables aisladas

3.6.3 Power Failure — PWF

La falla de potencia se relaciona con la potencia del proceso, calculada a partir del torque y la velocidad de rotación expresada en radianes por segundo.

La falla puede ocurrir cuando la potencia está por debajo de aproximadamente 3500 W o por encima de aproximadamente 9000 W.

Elemento	Descripción
Variables relacionadas	Torque y velocidad de rotación
Variable derivada posible	Potencia aproximada
Tipo de problema	Condición de potencia fuera de rango
Implicación	La ingeniería de características puede mejorar la representación del fenómeno

3.6.4 Overstrain Failure — OSF

La falla por sobreesfuerzo se relaciona con el producto del desgaste de la herramienta y el torque. El umbral varía según el tipo de producto.

Tipo de producto	Umbral aproximado de sobreesfuerzo
`L`	11,000 minNm
`M`	12,000 minNm
`H`	13,000 minNm

Elemento	Descripción
Variables relacionadas	Tipo, desgaste y torque
Tipo de problema	Carga acumulada o sobreesfuerzo
Implicación	Las variables categóricas pueden modificar la interpretación de una condición numérica

3.6.5 Random Failure — RNF

La falla aleatoria tiene una probabilidad independiente de aproximadamente 0.1 % por proceso. Por su naturaleza, puede ser difícil de predecir a partir de las variables disponibles.

Elemento	Descripción
Tipo de fenómeno	Evento aleatorio
Relación con sensores	Puede no existir una señal clara previa
Implicación	No todas las fallas son igualmente predecibles
Riesgo	Penalizar al modelo por no predecir eventos sin patrón observable

3.7 Variable objetivo principal

La variable `Machine failure` representa la etiqueta binaria principal del dataset. En el archivo oficial comprobado, 339 de 10,000 registros tienen valor `1` y 9,661 tienen valor `0`.

Una limitación importante es que la variable agregada no siempre permite conocer qué modo específico originó la falla. Por este motivo, PredictMain debe diferenciar entre:

- **Predicción binaria:** falla o no falla.
- **Diagnóstico multiclase:** qué tipo de falla puede estar relacionado.
- **Análisis de causa:** interpretación técnica de la combinación de variables.

3.8 Auditoría reproducible del archivo oficial

La siguiente tabla proviene de la lectura directa del archivo `ai4i2020.csv` descargado desde el repositorio oficial de UCI. La auditoría se realizó sin modificar, limpiar ni balancear los registros.

Verificación	Resultado observado	Interpretación
Nombre del archivo	`ai4i2020.csv`	Archivo oficial incluido en el ZIP de UCI.
Registros	10,000	Coincide con la documentación oficial.
Columnas	14	Coincide con la documentación oficial.
Valores faltantes	0	El archivo no contiene nulos en esta versión.
Filas duplicadas completas	0	No se encontraron duplicados exactos.
Identificadores `UDI`	10,000 valores únicos	Cada registro tiene un identificador único.
`Product ID`	10,000 valores únicos	Cada producto tiene un identificador distinto.
Fallas de máquina	339	3.39 % de los registros.
Registros sin falla	9,661	96.61 % de los registros.
Tipo L	6,000	60.00 % de los registros.
Tipo M	2,997	29.97 % de los registros.
Tipo H	1,003	10.03 % de los registros.

3.8.1 Rangos observados en el archivo

Variable	Mínimo	Máximo	Promedio	Desviación estándar
Temperatura del aire [K]	295.3	304.5	300.0049	2.0003
Temperatura del proceso [K]	305.7	313.8	310.0056	1.4837
Velocidad de rotación [rpm]	1,168	2,886	1,538.7761	179.2841
Torque [Nm]	3.8	76.6	39.9869	9.9689
Desgaste de herramienta [min]	0	253	107.9510	63.6541

3.8.2 Conteo comprobado de los modos de falla

Código	Modo de falla	Registros con etiqueta `1`	Porcentaje sobre 10,000
TWF	Tool Wear Failure	46	0.46 %
HDF	Heat Dissipation Failure	115	1.15 %
PWF	Power Failure	95	0.95 %
OSF	Overstrain Failure	98	0.98 %
RNF	Random Failure	19	0.19 %

Los modos pueden aparecer simultáneamente en un mismo registro. En la auditoría se observaron 324 registros con un modo activo, 23 con dos modos activos y 1 con tres modos activos. También se observaron 9 registros donde `Machine failure=1` no coincide con ningún indicador específico activo y 18 registros con algún indicador específico activo pero `Machine failure=0`. Esta inconsistencia entre columnas debe conservarse como hallazgo de calidad y revisarse antes de utilizar simultáneamente la etiqueta agregada y las etiquetas de modo como objetivos del modelo.

3.8.3 Diferencia entre documentación y datos observados

Aspecto	Documentación de UCI	Archivo comprobado	Decisión para PredictMain
Naturaleza	Dataset sintético que representa datos industriales	Confirmado mediante archivo oficial	Declararlo sintético, no real de planta.
Registros	10,000	10,000	Aceptado.
Columnas	14	14	Aceptado.
Valores faltantes	No	0 valores faltantes	Aceptado.
Distribución L/M/H	Descripción conceptual en la documentación	60.00/29.$^{97}/_{10}$.03 %	Utilizar los conteos reales del archivo.
Fallas	Reglas generativas descritas	339 etiquetas agregadas	Utilizar el archivo como fuente de verdad experimental.
Modos específicos	Reglas TWF/HDF/PWF/OSF/RNF descritas	Conteos y solapamientos comprobados	Validar consistencia antes del modelado multiclase.

> **Regla de trazabilidad:** cuando una cifra de la descripción y una cifra calculada del archivo difieran, PredictMain conservará ambas: la primera como información documental y la segunda como resultado de auditoría del archivo utilizado.

---

4. Investigación 1: comparación de modelos, balanceo y selección de características

4.1 Identificación

Título: *Comparative Evaluation of Machine Learning Models for Predictive Maintenance Using the AI4I 2020 Dataset: Effects of Data Balancing and Feature Selection*
Autores: Juan Carlos Gonzalez Islas, Jesus Vargas-Ortiz, Aldo Márquez-Grajales, Ernesto Bolaños-Rodríguez, Asdrúbal López-Chau y Rosa María Ortega-Mendoza
Año: 2026
Revista: ITEGAM-JETIA
DOI: 10.5935/jetia.v12i60.3878

4.2 Propósito

La investigación compara varios algoritmos de aprendizaje automático para clasificar fallas de máquinas usando AI4I 2020. También estudia cómo afectan al desempeño del modelo las estrategias de balanceo de datos y la selección de características.

4.3 Modelos evaluados

Modelo	Tipo	Uso dentro del estudio
Random Forest	Ensamble de árboles	Clasificación robusta y comparación principal.
Decision Tree / J48	Árbol de decisión	Modelo interpretable.
ANN	Red neuronal artificial	Comparación con modelos no lineales.
KNN	Basado en vecinos	Clasificación por similitud.
Naive Bayes	Probabilístico	Línea de comparación sencilla.

4.4 Escenarios de datos

Escenario	Descripción
Dataset original	Conserva la distribución desbalanceada.
SMOTE	Genera ejemplos sintéticos de la clase minoritaria.
Undersampling	Reduce ejemplos de la clase mayoritaria.
Conjunto completo de características	Utiliza todas las variables consideradas.
Conjunto reducido	Utiliza un subconjunto seleccionado de variables.

4.5 Métricas

Métrica	Qué indica
Accuracy	Proporción total de clasificaciones correctas.
Precision	Proporción de predicciones positivas que realmente son positivas.
Recall	Proporción de fallas reales detectadas.
Specificity	Capacidad para reconocer la clase negativa.
F1-score	Equilibrio entre precision y recall.

4.6 Conocimiento incorporado al corpus

- La accuracy puede resultar engañosa cuando las fallas son poco frecuentes.

- El recall de la clase de falla es especialmente importante para mantenimiento predictivo.
- Las técnicas de balanceo deben evaluarse, no aplicarse automáticamente.
- La selección de características puede reducir ruido y complejidad.
- Un conjunto de variables reducido no necesariamente es peor que uno completo.
- Las conclusiones dependen del modelo, distribución y escenario de datos.

4.7 Aplicación en PredictMain

Esta investigación respalda la necesidad de comparar una línea base con modelos como Random Forest y XGBoost, registrar la distribución de clases y analizar falsos negativos. También justifica que la selección de variables sea una decisión documentada y no una eliminación arbitraria de columnas.

---

5. Investigación 2: modelos de machine learning y deep learning con AI4I 2020

5.1 Identificación

Título: *Evaluating Machine Learning and Deep Learning Models for Predictive Maintenance: A Study Using the AI4I 2020 Dataset*
Autores: Rajesh R. Waghulde, Rajesh Kumar Rai, Ram Milan Chadhar, Milind Rane y Vijeta Yadav
Año: 2025
Revista: Journal of Neonatal Surgery

5.2 Propósito

El estudio evalúa modelos de machine learning y deep learning para anticipar fallas de maquinaria utilizando AI4I 2020.

5.3 Modelos analizados

Modelo	Característica
Random Forest	Ensamble de árboles y modelo robusto para datos tabulares.
SVM	Clasificador basado en fronteras de separación.
XGBoost	Ensamble de boosting con alto desempeño en datos tabulares.
Red neuronal profunda	Modelo capaz de aprender relaciones no lineales complejas.

5.4 Métricas utilizadas

- Accuracy.
- Precision.
- Recall.

- F1-score.

5.5 Hallazgo principal

La investigación reporta valores de F1-score superiores a 0.995 en varios clasificadores y tipos de falla. El artículo relaciona este comportamiento con:

- La calidad del dataset.
- Relaciones claras entre características y etiquetas.
- Bajo nivel de ruido.
- Naturaleza sintética del conjunto de datos.

5.6 Interpretación crítica

Los resultados altos no deben interpretarse automáticamente como evidencia de que el modelo está listo para una planta real. Un dataset sintético y limpio puede ser más fácil de clasificar que datos obtenidos de sensores industriales con:

- Ruido.
- Valores faltantes.
- Cambios de calibración.
- Lecturas irregulares.
- Diferentes condiciones de operación.
- Fallas no representadas en el entrenamiento.

5.7 Aplicación en PredictMain

Esta investigación aporta modelos candidatos y métricas de comparación, pero también introduce una regla de interpretación:

> Un resultado excelente en AI4I 2020 debe acompañarse de un análisis de generalización, limitaciones y diferencia entre datos sintéticos y datos industriales.

---

6. Investigación 3: escasez de datos, desbalance y selección de características

6.1 Identificación

Título: *Strategies for Overcoming Data Scarcity, Imbalance, and Feature Selection Challenges in Machine Learning Models for Predictive Maintenance*
Autor: Ali Hakami
Año: 2024

Revista: Scientific Reports
DOI: 10.1038/s41598-024-59958-9

6.2 Problemas abordados

Problema	Descripción
Escasez de datos	Existen pocos ejemplos de fallas en comparación con datos normales.
Desbalance	La clase normal puede dominar el conjunto de entrenamiento.
Dependencia temporal	Las lecturas de sensores pueden depender de mediciones previas.
Selección de características	No todas las variables contienen la misma información predictiva.
Horizonte de falla	Es necesario definir qué periodo se considera cercano a una falla.

6.3 Técnicas utilizadas

Técnica	Finalidad
Generación de datos sintéticos	Aumentar la representación de situaciones poco frecuentes.
GAN	Generar datos con patrones similares a los observados.
LSTM	Extraer patrones temporales de secuencias.
Failure horizon	Definir una ventana alrededor del evento de falla.
Extracción temporal	Construir características que representen evolución y tendencia.

6.4 Resultados reportados

El estudio reporta resultados de clasificación para diferentes modelos después de utilizar estrategias de generación y extracción temporal:

Modelo	Accuracy reportada
ANN	88.98 %
Random Forest	74.15 %
Decision Tree	73.82 %
KNN	74.02 %
XGBoost	73.93 %

Estos valores deben interpretarse dentro del contexto experimental de la investigación y no como resultados directamente transferibles a PredictMain.

6.5 Aplicación en PredictMain

Esta fuente ayuda a comprender que un modelo puede mostrar accuracy alta y, aun así, fallar en la clase minoritaria. Para PredictMain, la evaluación deberá analizar:

- Recall de la clase de falla.
- Falsos negativos.
- Distribución de fallas por tipo.
- Efecto del balanceo.
- Posible dependencia entre registros.
- Calidad de los datos antes del entrenamiento.

---

7. Investigación 4: mantenimiento predictivo en Industry 4.0

7.1 Identificación

Título: *Predictive Maintenance in Industry 4.0: A Survey of Planning Models and Machine Learning Techniques*
Autores: Ida Hector y Rukmani Panjanathan
Año: 2024
Revista: PeerJ Computer Science
DOI: 10.7717/peerj-cs.2016

7.2 Propósito

La investigación presenta una revisión de modelos de planeación y técnicas de aprendizaje automático utilizadas en mantenimiento predictivo dentro de Industry 4.0.

7.3 Etapas del mantenimiento predictivo

Etapa	Conocimiento principal
Captura de datos	Sensores, IoT y sistemas de monitoreo generan información operativa.
Preparación	Se revisan calidad, valores faltantes, outliers y consistencia.
Selección de características	Se identifican las variables más útiles para representar el estado del equipo.
Modelado	Se aplican algoritmos de clasificación, regresión o detección de anomalías.
Monitoreo	Se observa el estado del activo durante la operación.
Decisión	La predicción se transforma en una acción de inspección o mantenimiento.
Mejora continua	Se actualizan modelos y procesos con nueva evidencia.

7.4 Técnicas identificadas

Técnica	Aplicación en mantenimiento predictivo
Random Forest	Clasificación de defectos y fallas.
XGBoost	Modelado de estados y predicción con datos tabulares.
SVM	Clasificación de condiciones de equipos.
Redes neuronales	Relaciones no lineales y reconocimiento de patrones.
LSTM	Series temporales y degradación progresiva.
Clustering	Agrupación de estados operativos.
Isolation Forest	Detección de anomalías.
PCA	Reducción y selección de características.
TF-IDF	Extracción de características en registros textuales de mantenimiento.

7.5 Conocimiento incorporado

- El mantenimiento predictivo es un proceso completo, no únicamente un algoritmo.
- Los datos deben relacionarse con decisiones operativas.
- La selección de características influye en la calidad del modelo.
- El conocimiento de dominio ayuda a interpretar anomalías.
- La detección de anomalías puede identificar comportamientos inusuales, pero no siempre explica la causa exacta.
- La arquitectura IoT permite obtener datos continuamente, pero introduce retos de volumen, latencia y calidad.

---

8. Investigación 5: mejora del mantenimiento predictivo con XGBoost y ventana deslizante

8.1 Identificación

Título: *Enhancing Predictive Maintenance Method Using Machine Learning to Improve IoT-Embedded Machinery Efficiency and Performance*
Autores: Abiinesh Nadarajan, Iskandar Ishak, Noridayu Manshor, Raihani Mohamed y Mohamad Yusnisyahmi Yusof
Año: 2025
Revista: International Journal of Advanced Computer Science and Applications, volumen 16, número 10

Fuente: IJACSA — PDF del artículo

8.2 Problema investigado

El artículo parte de la dificultad de alcanzar simultáneamente:

- Alta precisión.
- Bajo tiempo de entrenamiento.
- Baja latencia de predicción.
- Capacidad para procesar grandes volúmenes de datos.
- Manejo de datasets desbalanceados.
- Adaptabilidad a maquinaria integrada con IoT.

8.3 Método propuesto

La investigación propone un método denominado **E.XGB**, basado en:

- Método de ventana deslizante.
- Modelo XGBoost.
- Preprocesamiento avanzado.
- Importancia por permutación.
- Optimización de hiperparámetros.
- Validación cruzada.

8.4 Datasets utilizados

Dataset	Naturaleza	Propósito
AI4I 2020	Sintético	Evaluar el método en un dataset de referencia reproducible.
CNC Milling Dataset	Real	Evaluar el método en condiciones más cercanas a un entorno industrial.

El uso de dos datasets busca reducir la dependencia de un único conjunto de datos y analizar la robustez frente a distribuciones diferentes.

8.5 Metodología

El estudio utiliza CRISP-DM como marco metodológico. Las actividades descritas incluyen:

Fase	Actividad reportada
Comprensión y adquisición	Uso de datasets de mantenimiento predictivo.
Preprocesamiento	Limpieza, tratamiento del desbalance, suavizado y estandarización.
División	Separación aproximada de 80 % para entrenamiento y 20 % para prueba.
Creación del modelo	Replicación de un modelo previo y creación de modelos de referencia.
Importancia de variables	Análisis de características antes del entrenamiento.
Optimización	Ajuste de hiperparámetros y validación cruzada.
Evaluación	Métricas, matriz de confusión y curvas ROC.
Comparación	Contraste con AdaBoost, Decision Tree, Random Forest y SVM.

8.6 Modelos comparados

Modelo	Papel
E.XGB	Método propuesto con XGBoost y ventana deslizante.
Decision Tree	Modelo de referencia.
Random Forest	Ensamble de árboles de referencia.
SVM	Modelo de clasificación comparativo.
AdaBoost / E.AB	Método usado como referencia adicional.

8.7 Métricas utilizadas

- Accuracy.
- Precision.
- Recall.
- F1-score.
- ROC-AUC.
- Tiempo de entrenamiento.
- Tiempo de predicción.
- Latencia.

8.8 Resultados reportados

Dataset	Accuracy reportada para E.XGB
AI4I 2020	99.05 %
CNC Milling	99.01 %

El artículo también reporta mejoras aproximadas de velocidad frente al método de referencia E.AB:

Indicador	Mejora reportada
Velocidad de entrenamiento	Aproximadamente 94 %
Velocidad de predicción	Aproximadamente 99.8 %

Estas cifras pertenecen al contexto experimental del artículo y no deben transferirse directamente a PredictMain sin reproducir las condiciones, particiones, variables, hardware y configuraciones utilizadas.

8.9 Aporte para PredictMain

Esta investigación aporta cuatro ideas relevantes:

1. **La accuracy no es suficiente:** también deben medirse tiempos de entrenamiento y predicción.
2. **La validación con más de un dataset mejora el análisis:** AI4I 2020 permite reproducibilidad y CNC Milling aporta mayor cercanía al mundo real.
3. **XGBoost es un candidato importante para datos tabulares:** especialmente cuando se combina con selección de variables y ajuste de hiperparámetros.
4. **CRISP-DM es compatible con el desarrollo del proyecto:** permite organizar comprensión, preparación, modelado y evaluación.

8.10 Precauciones de interpretación

- AI4I 2020 es sintético y no contiene todos los problemas de una captura industrial real.
- El uso de ventana deslizante puede modificar la representación temporal de los datos.
- Los resultados dependen de la partición, preprocesamiento y configuración experimental.
- La velocidad reportada depende del hardware y del entorno de ejecución.
- La validación cruzada debe aplicarse sin permitir fuga de información entre entrenamiento y prueba.

---

9. Comparación general de las investigaciones

Fuente	Dataset	Modelos o método	Problema principal	Aporte para PredictMain
Gonzalez Islas et al.	AI4I 2020	RF, DT, ANN, KNN, Naive Bayes	Balanceo y selección de características	Comparar modelos y estudiar desbalance.
Waghulde et al.	AI4I 2020	RF, SVM, XGBoost y deep learning	Desempeño de ML/DL y generalización	Analizar resultados altos con cautela.
Hakami	Dataset de mantenimiento predictivo	GAN, LSTM, ANN, RF, DT, KNN y XGBoost	Escasez, desbalance y temporalidad	Estudiar fallas minoritarias y ventanas de falla.
Hector y Panjanathan	Diversos estudios	ML, IoT, detección de anomalías y RUL	Planeación integral de PdM	Entender el ciclo completo del dominio.
Nadarajan et al.	AI4I 2020 y CNC Milling	E.XGB, XGBoost, DT, RF, SVM y AdaBoost	Precisión, velocidad y latencia	Relacionar desempeño del modelo con tiempo real.

10. Conocimiento consolidado sobre los datos

10.1 Datos normales y datos de falla

El dataset contiene muchas más observaciones de operación normal que de falla. Esta característica puede producir un modelo con accuracy alta pero con poca capacidad para detectar fallas reales.

Por ello, deben distinguirse:

Concepto	Significado
Verdadero positivo	El modelo identifica una falla que realmente ocurrió.
Verdadero negativo	El modelo identifica operación normal correctamente.
Falso positivo	El modelo anuncia una falla que no ocurrió.
Falso negativo	El modelo no detecta una falla real.

En mantenimiento predictivo, el falso negativo puede ser especialmente costoso porque representa una falla no detectada.

10.2 Variables individuales y combinadas

Algunas fallas no dependen de una sola variable. Pueden surgir de la relación entre varias mediciones.

Relación	Fenómeno que puede representar
Temperatura del proceso − temperatura del aire	Disipación térmica.
Torque × velocidad angular	Potencia aproximada.
Desgaste × torque	Sobreesfuerzo.
Tipo de producto + desgaste	Umbral de carga dependiente de la variante.
Velocidad + temperatura	Condiciones operativas combinadas.

10.3 Importancia de la ingeniería de características

La ingeniería de características puede ayudar a expresar mejor fenómenos físicos y operativos. Sin embargo, debe realizarse sin fuga de información.

Las transformaciones y estadísticas utilizadas para entrenar el modelo deben ajustarse únicamente con el conjunto de entrenamiento y aplicarse después al conjunto de prueba.

---

11. Conocimiento consolidado sobre los modelos

Modelo	Fortalezas	Precauciones
Random Forest	Robusto, útil para datos tabulares y relativamente interpretable.	Puede producir modelos grandes y no siempre optimiza latencia.
XGBoost	Alto desempeño en datos tabulares, flexible y eficiente.	Requiere ajuste de hiperparámetros y control contra sobreajuste.
Decision Tree	Fácil de explicar y visualizar.	Puede sobreajustarse y ser inestable ante pequeños cambios.
SVM	Eficaz en problemas de clasificación con fronteras complejas.	Puede ser costoso con grandes volúmenes y requiere escalamiento.
KNN	Sencillo y basado en similitud.	La predicción puede ser lenta y sensible a escalas.
Naive Bayes	Rápido y sencillo como línea base.	Sus supuestos de independencia pueden ser poco realistas.
ANN	Capaz de aprender relaciones no lineales.	Requiere configuración, datos y control de interpretabilidad.
LSTM	Adecuado para secuencias y dependencia temporal.	Mayor complejidad y necesidad de secuencias bien estructuradas.
GAN	Puede generar ejemplos sintéticos.	Los datos generados no sustituyen automáticamente los datos reales.

---

12. Métricas de evaluación consolidadas

Métrica	Pregunta que responde	Importancia en PredictMain
Accuracy	¿Qué proporción total clasificó correctamente?	Útil, pero insuficiente con desbalance.
Precision	De las alertas emitidas, ¿cuántas fueron correctas?	Ayuda a reducir falsas alarmas.
Recall	De las fallas reales, ¿cuántas detectó?	Fundamental para reducir fallas no detectadas.
F1-score	¿Existe equilibrio entre precision y recall?	Útil cuando ambas importan.
Specificity	¿Qué tan bien reconoce la operación normal?	Ayuda a controlar falsas alarmas.
ROC-AUC	¿Qué tan bien separa las clases en distintos umbrales?	Permite comparar capacidad discriminativa.
PR-AUC	¿Qué tan bien identifica positivos en clases desbalanceadas?	Puede ser más informativa cuando la falla es rara.
Matriz de confusión	¿Qué tipos de aciertos y errores produce?	Permite analizar falsos positivos y negativos.
Tiempo de entrenamiento	¿Cuánto tarda en actualizarse el modelo?	Importante para mantenimiento y reentrenamiento.
Latencia de predicción	¿Cuánto tarda en producir una predicción?	Importante para alertas cercanas al tiempo real.

13. Principales riesgos técnicos identificados

Riesgo	Explicación
Generalización limitada	Un modelo puede funcionar en AI4I 2020 y fallar con datos reales.
Desbalance	La clase normal puede ocultar el bajo desempeño en fallas.
Datos sintéticos	Las relaciones entre variables pueden ser demasiado claras o artificiales.
Fuga de información	Una transformación mal aplicada puede usar información del conjunto de prueba.
Sobreajuste	El modelo puede memorizar patrones del dataset.
Falla aleatoria	RNF puede no tener una señal observable.
Interpretación incorrecta	Correlación no significa necesariamente causa física.
Variables redundantes	Algunas columnas pueden duplicar o derivar información ya disponible.
Ventanas temporales inadecuadas	Una ventana puede mezclar registros o introducir dependencia artificial.
Métrica insuficiente	Accuracy alta puede ocultar muchos falsos negativos.
Dependencia de hardware	Los tiempos reportados no son universales.
Cambio de distribución	Una máquina real puede operar en condiciones diferentes.

14. Reglas de interpretación para PredictMain

1. **No considerar AI4I 2020 como una planta real.** Es un dataset sintético diseñado para representar condiciones de mantenimiento predictivo.
2. **No aceptar accuracy como única evidencia.** Se deben revisar recall, precision, F1-score y matriz de confusión.
3. **Priorizar el análisis de falsos negativos.** Una falla no detectada puede tener mayor costo operativo que una falsa alarma.
4. **Separar predicción de diagnóstico.** Predecir que existe una falla no equivale a identificar su causa.
5. **Registrar la distribución de clases.** Toda evaluación debe indicar cuántas observaciones corresponden a cada clase.
6. **Comparar modelos con la misma partición.** Las diferencias de desempeño solo son válidas si las condiciones son comparables.
7. **Prevenir fuga de información.** El preprocesamiento debe ajustarse dentro del conjunto de entrenamiento.
8. **Documentar variables derivadas.** Toda característica nueva debe tener una interpretación técnica.
9. **Validar con datos diferentes cuando sea posible.** Un segundo dataset puede revelar problemas de generalización.

10. **Consultar al experto del dominio.** Las relaciones estadísticas deben contrastarse con el comportamiento de la maquinaria.
11. **Medir rendimiento operativo.** Si se busca tiempo real, deben medirse entrenamiento, inferencia y latencia.
12. **Distinguir evidencia publicada de decisión del proyecto.** Un artículo puede orientar, pero no sustituye la validación de PredictMain.

---

15. Glosario técnico

Término	Definición sencilla
Mantenimiento predictivo	Estrategia que utiliza datos para anticipar fallas y planificar acciones.
Telemetría	Datos obtenidos de sensores o sistemas de operación.
Machine learning	Métodos que aprenden patrones a partir de datos.
Clasificación	Asignación de una observación a una categoría.
Falla binaria	Clasificación entre falla y no falla.
Falla multiclase	Clasificación entre varios tipos de falla.
Desbalance	Diferencia importante en el número de ejemplos de cada clase.
SMOTE	Técnica que genera ejemplos sintéticos de una clase minoritaria.
Undersampling	Reducción de ejemplos de la clase mayoritaria.
Feature	Variable utilizada por un modelo.
Selección de características	Elección de las variables más útiles para predecir.
Ingeniería de características	Creación o transformación de variables para representar mejor un fenómeno.
Ventana deslizante	Segmento móvil de observaciones usado para analizar una secuencia.
Recall	Proporción de positivos reales que el modelo detecta.
Falso negativo	Falla real que el modelo clasifica como normal.
Falso positivo	Alerta de falla que no corresponde a una falla real.
XGBoost	Algoritmo de boosting basado en árboles de decisión.
Random Forest	Ensamble de múltiples árboles de decisión.
LSTM	Red neuronal recurrente orientada a secuencias y dependencias temporales.
ROC-AUC	Medida de capacidad de separación entre clases.
Latencia	Tiempo que tarda el sistema en responder o producir una predicción.
Generalización	Capacidad de funcionar correctamente con datos no utilizados durante el entrenamiento.
CRISP-DM	Metodología cíclica para proyectos de minería de datos.
IoT	Conjunto de dispositivos y sensores conectados que generan datos.

16. Síntesis final del corpus

El conocimiento reunido permite establecer las siguientes conclusiones para PredictMain:

- AI4I 2020 es una base adecuada para iniciar la experimentación, pero es sintética.
- Las fallas están relacionadas con condiciones físicas y combinaciones de variables.
- El desbalance es un problema central en la clasificación de fallas.
- Recall, F1-score y matriz de confusión son esenciales para valorar el modelo.
- Random Forest y XGBoost son candidatos sólidos para datos tabulares.
- SVM, árboles, KNN, redes neuronales y LSTM pueden servir para comparación según el tipo de datos.
- La selección de características debe justificarse técnicamente.
- La creación de variables derivadas puede representar mejor fenómenos como potencia, disipación térmica y sobreesfuerzo.
- Los datos sintéticos pueden producir resultados demasiado optimistas.
- La validación con un dataset real o con datos de otro contexto aumenta la confianza en la generalización.
- La investigación reciente propone combinar ventana deslizante, XGBoost, importancia por permutación y optimización de hiperparámetros.
- La velocidad de entrenamiento y la latencia de predicción son relevantes cuando el sistema debe operar cerca del tiempo real.
- CRISP-DM proporciona una estructura adecuada para avanzar desde la comprensión del negocio hasta la evaluación del modelo.
- El experto del dominio es necesario para verificar que los patrones estadísticos tengan sentido industrial.

> **Conclusión del corpus:** PredictMain debe construirse como un sistema de análisis experimental, trazable y progresivo. Primero debe comprender los datos y sus limitaciones; después comparar modelos con métricas adecuadas; finalmente, comprobar si los resultados se mantienen fuera del dataset sintético antes de presentar el modelo como una solución aplicable a maquinaria real.

---

17. Documentación primaria del dataset

17.1 Fuente oficial UCI

La ficha oficial de UCI identifica AI4I 2020 como un dataset sintético que refleja datos de mantenimiento predictivo encontrados en la industria. También registra 10,000 instancias, 14 columnas, tareas de clasificación y regresión, ausencia de valores faltantes y la licencia CC BY 4.0.

La ficha oficial debe considerarse la referencia principal para: nombre del dataset, archivo de descarga, variables, licencia, DOI y procedencia.

17.2 Artículo introductorio de Stephan Matzka

El artículo *Explainable Artificial Intelligence for Predictive Maintenance Applications*, presentado en 2020, introduce un dataset realista pero sintético para aplicaciones de mantenimiento predictivo explicable. Es la fuente académica primaria

asociada al dataset en la ficha de UCI.

Su importancia para PredictMain es doble:

1. Explica el propósito experimental del dataset.
2. Confirma que el conjunto no debe presentarse como medición histórica real de una planta.

17.3 Evidencia de descarga utilizada

La auditoría de esta versión se realizó sobre el ZIP oficial de UCI:

- URL: `https://archive.ics.uci.edu/static/public/601/ai4i+2020+predictive+maintenance+dataset.zip`
- Archivo interno: `ai4i2020.csv`
- Copia local auditada: `PredictMain_AI4I2020_Oficial.csv`
- Registros leídos: 10,000
- Columnas leídas: 14
- Valores faltantes encontrados: 0
- Duplicados completos encontrados: 0
- Transformaciones aplicadas antes de la auditoría: ninguna
- SHA-256 de la copia auditada: `dc6630cd9b1f0f853922fad78a1b6436570d3f1ec863f1dd5c4340ac56bc8a8e`

---

18. Catálogo de fuentes

ID	Referencia	Enlace
SRC-001	Gonzalez Islas et al. (2026). *Comparative Evaluation of Machine Learning Models for Predictive Maintenance Using the AI4I 2020 Dataset: Effects of Data Balancing and Feature Selection*.	ITEGAM-JETIA
SRC-002	Waghulde et al. (2025). *Evaluating Machine Learning and Deep Learning Models for Predictive Maintenance: A Study Using the AI4I 2020 Dataset*.	Journal of Neonatal Surgery
SRC-003	Hakami (2024). *Strategies for Overcoming Data Scarcity, Imbalance, and Feature Selection Challenges in Machine Learning Models for Predictive Maintenance*.	Scientific Reports / Nature
SRC-004	Hector y Panjanathan (2024). *Predictive Maintenance in Industry 4.0: A Survey of Planning Models and Machine Learning Techniques*.	PeerJ Computer Science / PMC
SRC-005	Nadarajan et al. (2025). *Enhancing Predictive Maintenance Method Using Machine Learning to Improve IoT-Embedded Machinery Efficiency and Performance*.	IJACSA PDF
SRC-006	UCI Machine Learning Repository. *AI4I 2020 Predictive Maintenance Dataset*.	UCI Dataset
SRC-007	Matzka, S. (2020). *Explainable Artificial Intelligence for Predictive Maintenance Applications*.	IEEE Xplore